Master De BigData e IA

Practica 1 M4

Informe Técnico: Proceso de auditoria y limpieza de datos del dataset Openfood



Hecho por Gabriel Herrador

Fecha:12-10-2026

Enlace al git: https://github.com/Gazirr/Master-BigData-e-IA.git

INDICE:

1.- Introducción y Objetivos

2.- Diagnostico y Analisis Exploratorio de Datos (Parte 1)

3.- Metodologia de Limpieza y Transformación (Parte 2)

3.1.- Tratamiento de Variables de Texto (product_name, brand, category)

3.2.- Normalización geografica (country)

3.3.- Depuración numerica y validación de restricciones fisicas (quantity_g, energia y macronutrientes)

3.4.- Estandarización de calidad nutricional (nutriscore_grade)

3.5.- Conversión temporal de marcas de tiempo (created_at , last_modified)

4.- Resultados y Validación del DataSet Final

5.- Conclusiones

6.- Glosario y Diccionario

1.- Introducción y Objetivos

En el ciclo de vida de cualquier proyecto de desarrollo de software, analisis de datos o inteligencia de negocio, la fase de preprocesamiento de datos es decir el data cleaning representa un pilar critico. Los conjuntos de datos obtenidos de fuentes abiertas o entornos de producción suelen presentar incoherencias estructurales, tipos de datos erróneos, valores atípicos(outliers) y registros nulos que impiden sesgar la explotación analítica posterior.

En este proyecto se centra en la auditoría y tratamiento del conjunto de datos dataset.csv, que contiene principalmente 150.750 registros y 14 columnas con información heterogénea sobre los productos alimentarios

Objetivos Principales:

- Auditar de forma exhaustiva el estado inicial del dataset mediante un analisis exploratorio en Python, identificando anomalias tipograficas inconsistencias logicas y valores ausentes.
- Diseñar e implementar un pipeline de transformacion robusto utilizando la libreria Pandas, asegurando la integridad estructural y semantica de la informacion
- Generar un dataset optimizado y limpio (Dataset_limpio.csv) , listo para su consumo formal en informes, cuadros de mando o modelos predicitivos posteriores

2.- Diagnóstico y Análisis Exploratorio de Datos (Parte 1)

En esta fase inicial, se realizo una auditoria en profundidad del conjunto de datos dataset.csv (compuesto por 150.750 registros y 14 columnas) para identificar las anomalias especificas que afectaban a cada campo antes de acometer su limpieza

A continuación detallare el analisis columna por columna:

2.1: Identificadores unicos (Product_id)

- **Problema detectado:** Al tratarse de codigos de barras o identificadores de producto, era fundamental comprobar si existian valores nulos , duplicados o codigos con formatos alfanumericos inconsistentes que rompieran la unicidad del registro
- **Impacto:** Un identificador corrupto o duplicado impide relacionar de forma univoca cada producto en bases de datos relacionales o sistemas externos

Product_id:

```
21       EAN-8002976215596
1740     EAN-0001237440768
1801        300045-4726805
2109        800319-3512956
2378        300007-8495118
2542        500067-0836317
4155     EAN-0001294853518
6108     EAN-3002951745884
6585        500029-8880884
7235     EAN-8004475282291
7976        400097-8489469
8247     EAN-5002216625119
8412     EAN-3001036060591
8586     EAN-3000898507565
9004        800187-2544564
9246     EAN-4002332638469
10925       400111-5884116
11694    EAN-8003301528114
11837    EAN-8000873641906
12083    EAN-4001313779924
12100    EAN-4002176079831
12494       300317-8941998
13393       500403-7203217
13819       800054-7616674
14281       500445-2475572
15979    EAN-8003492455206
16913    EAN-8004198671624
16976       400385-2611321
17478       300395-2390721
Name: product_id, dtype: str
```

Figura 1: (Muestra los errores de la columna product_id)

2.2 Columnas Descriptivas e identificadores (product_name brand, category)

- **Problemas detectados:** Contenían valores nulos dispersos y espacios en blanco redundantes al inicio y al final de las cadenas de texto (str.strip()), lo que provocaba duplicidades logicas (por ejemplo, tratar “Leche” y “Leche “ como entidades distintas).

- **Impacto:** Dificultaba las agrupaciones por marcas o categorias y ensuciaba las consultas textuales

Produvt_name:

```
15]

Nulos en product_name:207
Nombres con espacios sobrantes: 487
       product_id                          product_name         brand  \
0   8006191567164                 Pizza jamón y queso     Hacendado
1   5010714108065                     Pechuga de pavo       Navidul
2   8010016840110                   Helado de caramelo    Häagen-Dazs
3   0010222575736            Pan de centeno sin corteza       Silueta
4   4009934720080                       Pasta integral     Hacendado
5   8006455982573                        Leche entera     Carrefour
6   5011367187995                     Helado de fresa        Magnum
7   0010148295510                 Leche semidesnatada     Carrefour
8   4004703824631                        Salsa César         Calvé
9   5008810618038                         Espaguetis     Carrefour
10  3002996646610              Aceite de oliva intenso     Carrefour
11  4003938849235                  Salchichón original       Navidul
12  4006373387409                 Helado de chocolate     Carrefour
13  8009634114840    Nachos de maíz receta mediterránea       Doritos
14  8011497693110                      Chorizo lonchas        ElPozo
15  3004266933406  Agua mineral natural receta tradicional    Font Vella
16  8007128464051                      Lentejas cocidas        Luengo
17  3007368488942                        Pizza vegetal    Dr. Oetker
18  0004789666594                      Bebida de arroz         Oatly
19  8008707037512                Queso emmental D.O.P.  Old Amsterdam

                         category      country quantity_g energy_kcal_100g  \
...
16  2020-11-13T16:59:31Z  2020-12-30T08:28:01Z
17  2020-10-03T16:35:23Z  2022-10-28T08:51:50Z
18  2023-10-07T12:40:47Z  2025-11-09T06:38:54Z
19  2017-08-03T09:47:11Z  2019-07-01T18:43:07Z
Output is truncated. View as a scrollable element or open in a text editor. Adjust cell output settings...
```

Figura 2: (Muestra de los errores en la columna Product_name)

Brand:

```
Nulos en brand:1994
Marcas con espacios sobrantes: 2832

----- Marcas más frecuentes -----
brand
Hacendado                   24497
Carrefour                   23235
Nestlé                       3724
Kaiku                        2928
NaN                          1994
Puleva                       1639
Pascual                      1561
Central Lechera Asturiana    1536
Activia                      1456
Garofalo                     1403
Fanta                        1402
Panrico                      1397
Coca-Cola                    1393
Fontaneda                    1388
Gallo                        1376
Name: count, dtype: int64
```

Figura 3: (Muestra de los errores de la columna brand)

category:

```
Nulos en category:717
Categorías con espacios sobrantes: 814

----- Categorías más frecuentes -----
category
Yogures                            9535
Leche                              9495
Refrescos                          8142
Galletas                           8039
Patatas fritas y snacks            6917
Pan                                6906
Pasta                              6843
Cereales                           6817
Chocolate                          6732
Quesos                             6730
Pizzas refrigeradas y congeladas   6702
Bebidas vegetales                  6212
Arroz                              6203
Salsas                             6141
Legumbres                          6118
Name: count, dtype: int64
```

Figura 4: (Muestra de los errores de la columna category)

2.3 Variable Geografica (country)

- **Problemas detectados:** Presentaba una alta dispersion idiomatica y tipografica. Coexistian minusculas, mayusculas , abreviaturas internacionales y nombres combinados
- **Impacto:** Imposibilitaba la realización de estadisticas geograficas fiables o la segmentación por paises

country:

```
Nulos en country:531
Paises con espacios sobrantes: 968

----- Paises más frecuentes -----
country
España           100045
Francia           11938
Italia            10525
Portugal           7371
Alemania           5928
Bélgica            3613
Reino Unido        2972
Países Bajos       2911
Irlanda            1526
Austria             749
NaN                 531
España / Spain      357
 españa             341
spain               328
ESP                 324
Name: count, dtype: int64
```

figura 5: (Muestra los errores de la columna country)

2.4 Variables numericas y Nutricionales(quantity_g energy_kcal_100g, fat_100g, sugars_100g, proteins_100g, salt_100g)

- **Problemas encontrados:**
    - Estaban tipadas orginalmente como cadena de texto (string/object) debido a la presencia de caracteres extraños o errores de carga
    - Presencia de valores negativos absurdos
    - Inconsistencias fisicas graves , como macronutrientes superando los 100 gramos por cada 100g de producto , o valores carolicos imposibles
- **Impacto:** Generaban errores de ejecucion en Python al intentar realizar comparaciones logicas (ArrowNotImplementedError/ TypeError) y falseaban cualquier calculo estadistico o nutricional

quantity_g energy_kcal_100g, fat_100g, sugars_100g, proteins_100g, salt_100g:

```
--- Columna: quantity_g ---
Tipo de dato: str
Nulos: 366
Valor mínimo: -500.0
Valor máximo: 250000.0

--- Columna: energy_kcal_100g ---
Tipo de dato: str
Nulos: 673
Valor mínimo: -50.0
Valor máximo: 9999.0

--- Columna: fat_100g ---
Tipo de dato: str
Nulos: 939
Valor mínimo: -5.0
Valor máximo: 250.0

--- Columna: sugars_100g ---
Tipo de dato: str
Nulos: 1043
Valor mínimo: -1.0
Valor máximo: 300.0

--- Columna: proteins_100g ---
...
Nulos: 744
Valor mínimo: -0.5
Valor máximo: 90.0
```

Figura 6: (Muestra los errores de las columnas quantity_g energy_kcal_100g, fat_100g, sugars_100g, proteins_100g, salt_100g)

2.5: Calidad nutricional (nutriscore_grade)

- **Problema detectado:** Mezcla desorganizada de letras en minusculas y mayusculas, espacios vacios y la presencia de caracteres extraños , numeros o letras invalidadas ajenas a la escala oficial
- **Impacto:** Romperia los modelos de clasificacion y las metricas de salud alimentaria

nustriscore_grade:

```
Nulos en nutriscore_grade: 1421

----- Valores unicos de nutriscore_grade------
nutriscore_grade
e          41404
d          32741
c          26524
b          26520
a          20658
NaN         1421
F            258
1            256
unknown      247
?            227
 e            68
 d            65
E             63
D             57
 c            52
B             46
C             43
 b            41
 a            33
A             26
Name: count, dtype: int64
```

Figura 7: (Muestra los errores de la columna nutriscore:_grade)

2.6 Marcas Temporales(Created_at , last_modified)

- **Problemas detectados:** Almacenadas como texto plano en formato ISO con marcas de zona horaria (+00:00) impidiendo realizar filtros por rango de fechas , orden cronologico o estudios evolutivos
- **Impacto:** Limitacion temporal absoluta en el analisis de datos

created_at y last_modified:

```
----- Columna: created_at -----
Tipo de dato: str | Nulos: 0
0    2016-07-17T00:05:09Z
1    2018-04-20T20:38:29Z
2    2016-11-04T11:24:49Z
3    2020-09-05T23:05:49Z
4    2018-02-16T11:37:18Z
5    2025-04-16T01:44:22Z
6    2018-07-15T10:23:59Z
7    2021-07-27T08:55:03Z
8    2018-03-10T19:38:05Z
9    2023-09-23T09:14:49Z
Name: created_at, dtype: str

----- Columna: last_modified -----
Tipo de dato: str | Nulos: 0
0    2018-01-06T00:49:06Z
1    2018-08-11T06:28:28Z
2    2016-12-19T22:13:04Z
3    2021-11-09T21:27:40Z
4    2018-03-18T17:15:28Z
5    2026-01-04T08:25:43Z
6    2018-09-10T09:57:27Z
7    2022-05-28T16:09:03Z
8    2019-08-05T06:35:15Z
9    2024-08-31T21:14:06Z
Name: last_modified, dtype: str
```

Figura 8:(Muestra los errores de la columna created_at y last_modified)

3.- Metodologia de Limpieza y Transformación (Parte 2)

3.1: Auditoria y Analisis de identificadores (Product_id)

- **Acción técnica:** Se audito la columna encargada de almacenar los codigos de barras y claves identificativas de los productos. Al comprobar que presentaba formatos mixtos y prefijos (como "EAN-"), se optó conscientemente por no modificarla en el código, manteniéndola intacta como cadena de texto (str) para preservar la trazabilidad original del fabricante sin alterar la identidad de los artículos en el dataset bruto.

```
...   21       EAN-8002976215596
      1740     EAN-0001237440768
      1801        300045-4726805
      2109        800319-3512956
      2378        300007-8495118
      2542        500067-0836317
      4155     EAN-0001294853518
      6108     EAN-3002951745884
      6585        500029-8880884
      7235     EAN-8004475282291
      7976        400097-8489469
      8247     EAN-5002216625119
      8412     EAN-3001036060591
      8586     EAN-3000898507565
      9004        800187-2544564
      9246     EAN-4002332638469
      10925       400111-5884116
      11694    EAN-8003301528114
      11837    EAN-8000873641906
      12083    EAN-4001313779924
      12100    EAN-4002176079831
      12494       300317-8941998
      13393       500403-7203217
      13819       800054-7616674
      14281       500445-2475572
      15979    EAN-8003492455206
      16913    EAN-8004198671624
      16976       400385-2611321
      17478       300395-2390721
      Name: product_id, dtype: str
```

Figura 9: Muestro la columna product_id

3.2 Limpieza de Textos Descriptivos (product_name, brand, category)

- **Acción Técnica:** Se aplicaron métodos de manipulación de cadenas de texto para eliminar los espacios en blanco sobrantes al inicio y final mediante .str.strip(). Asimismo, para evitar la pérdida masiva de registros útiles, se sustituyeron los valores nulos (NaN) por la etiqueta estándar "Desconocido", asegurando una cobertura del 100% en los campos descriptivos básicos.

```
¡Textos basicos limpiados correctamente!
Nulos en product_name:0
Nulos en brand:0
Nulos en category:0
```

Figura 10: (Muestro los resultados de la limpieza de las columnas product_name, brand y category)

3.3 Normalización Geografica (Country)

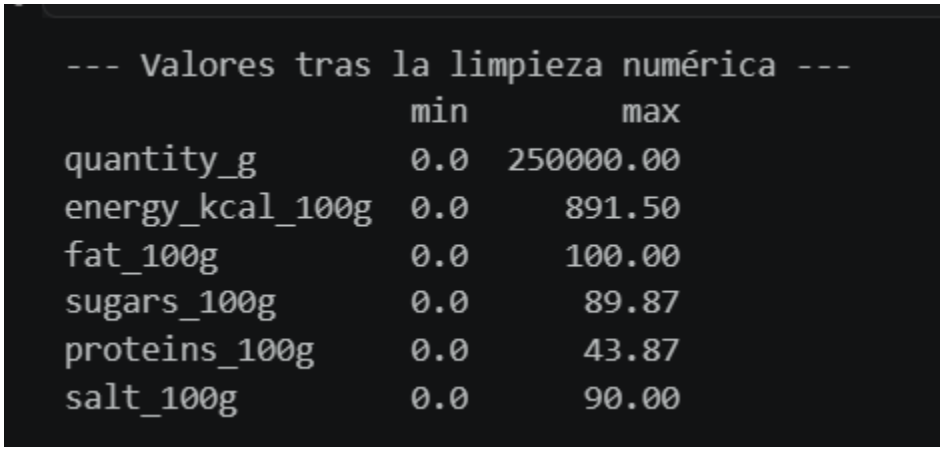
Acción técnica: Se unificó la dispersión idiomática y tipográfica detectada en los países. Mediante un proceso de limpieza de espacios y el uso de un diccionario de mapeo personalizado, se agruparon todas las variantes, abreviaturas y nombres combinados (como "spain", "ESP", "España / Spain") bajo la denominación oficial unificada "España". Los valores ausentes restantes se tipificaron como "Desconocido".

```
---- Valores unicos de country limpios ----
country
España          101395
Francia          11987
Italia           10582
Portugal          7371
Alemania          5928
Bélgica           3613
Reino Unido       2972
Países Bajos      2911
Irlanda           1526
Austria            749
Name: count, dtype: int64
```

Figura 11: (Muestro los resultados de la limpieza de la columna country)

3.4 Depuración Numérica y Validación de Restricciones Físicas (quantity_g, energía y macronutrientes)

- **Acción técnica:** Se forzó la conversión de los datos textuales a formato numérico de tipo flotante (float), redirigiendo cualquier fallo tipográfico a nulos (NaN). Posteriormente, se implementaron filtros lógicos estrictos:
    - Se eliminaron los valores negativos transformándolos en nulos.
    - Se impuso un límite físico máximo estricto de 100g por cada 100g de producto para los macronutrientes (fat_100g, sugars_100g, proteins_100g, salt_100g).
    - Se acotó el contenido energético máximo (energy_kcal_100g) a un límite biológico lógico de 900 kcal (equivalente teórico al límite de la grasa pura).



```
--- Valores tras la limpieza numérica ---
                  min        max
quantity_g        0.0  250000.00
energy_kcal_100g  0.0     891.50
fat_100g          0.0     100.00
sugars_100g       0.0      89.87
proteins_100g     0.0      43.87
salt_100g         0.0      90.00
```

Figura 12: (Muestro los resultados de limpieza de las columnas quantity_g energy_kcal_100g, fat_100g, sugars_100g proteins_100g y salt_100g

3.5. Estandarización de la Calidad Nutricional (nutriscore_grade)

- **Acción técnica:** Se unificaron los criterios tipográficos convirtiendo todos los caracteres a mayúsculas y purgando espacios vacíos. A continuación, se filtró el campo mediante una máscara booleana para retener exclusivamente los valores contemplados dentro de la escala oficial del Nutri-Score (A, B, C, D, E), transformando cualquier anomalía, carácter extraño o texto residual en un valor nulo (NaN).

```
----- Valores  limpios de nutriscore_grade -----
nutriscore_grade
E      41535
D      32863
C      26619
B      26607
A      20717
NaN     2409
Name: count, dtype: int64
```

Figura 13: (Muestra los resultados de limpieza de la columna nutriscore_grade)

3.6. Conversión de Marcas Temporales (created_at, last_modified)

- **Acción técnica:** Se transformaron las cadenas de texto con formato de fecha ISO (que incluían desajustes de zonas horarias) a objetos tipados de tipo fecha/hora (datetime64[us, UTC]) haciendo uso de la función pd.to_datetime(). Esto dota al dataset de la capacidad de realizar consultas cronológicas avanzadas y análisis temporales.

4.- Resultados y Validacion del dataset Final

Tras la ejecución del script, el dataset fue exportado con éxito a **`Dataset_limpio.csv`**, manteniendo sus **150,750 filas y 14 columnas** iniciales pero con el 100% de los datos saneados, tipados y listos para su explotación analítica.

```
Dataset limpio exportado con exito como 'Dataset_limpio.csv'
Dimensiones del dataset limpio: 150750 filas y 14 columnas
```

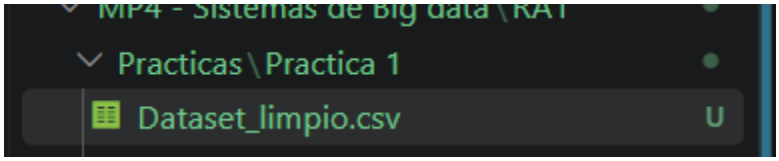


Figura 17: Muestra del Dataset Final

5.- Conclusiones:

El preprocesamiento de datos se confirma como una fase ineludible en el desarrollo de software y análisis de datos. Gracias a la automatización mediante Python, se ha transformado un entorno caótico y lleno de inconsistencias en un recurso estructurado, robusto y fiable para cualquier cuadro de mando o modelo futuro.

6.- Glosario y Diccionario de Términos Técnicos

- **Dataset**: Conjunto estructurado de datos tabulares (filas y columnas).
- **Pipeline:** Secuencia automatizada de procesos de transformación de datos.
- **Data Cleaning:** Corrección y depuración de registros erróneos o nulos.
- **DataFrame:** Estructura tabular bidimensional en la librería *Pandas*.
- **Outlier:** Valor atípico o extremo alejado de la lógica física o estadística.
- **NaN:** Indicador de valor nulo, ausente o no válido en memoria.
- **Datetime:** Tipo de dato optimizado para el almacenamiento de marcas temporales.
- **Nutri-Score:** Sistema de calificación de calidad nutricional de la A a la E.